

基于 Ridge 回归与 Chronos 模型的金融时间序列预测对比研究

Wang Shuning Sabrina 2502010376

1. 研究背景与目的

随着金融市场的快速发展，准确预测股票价格走势对投资者和金融机构具有重要意义。传统的统计方法与近年来兴起的深度学习方法在时间序列预测领域各有优势。本研究旨在：

- 比较 Ridge 回归模型与 Chronos 预训练时间序列模型在股票对数收益率预测任务中的表现；
- 探究两种模型在捕捉金融时间序列非线性特征与时序依赖方面的能力差异；
- 为金融时间序列预测提供一种兼具传统统计方法与深度学习方法的实验框架。

2.1 数据来源

实验使用来源于 Kaggle 网站的 S&P 500 成分股的日度实时更新收盘价数据，共包含 501 只股票。为了保证各股票时间长度一致，仅保留每只股票最近 250 个交易日的数据。

原始数据以宽表形式存储，本文将其转换为长表格式，使每一行对应某只股票在某一天的观测值，形成标准面板数据结构。

2.2 数据处理

- 数据清洗：**转换为面板数据格式，删除缺失值
- 收益率计算：**计算对数收益率 $r_t = \log(P_t/P_{t-1})$

该形式具有良好的数值稳定性和时间可加性，因此常用于金融建模。为了减弱异常点对模型的影响，对收益率进行截断处理，将其限制在 $[-0.2, 0.2]$ 区间内。

- 特征构建：**基于历史收益率构造

◇ 滞后特征：lag_1, lag_2, lag_3, lag_5, lag_10

◇ 滚动统计特征：滚动均值（窗口 5, 10, 20）、滚动标准差（窗口 5, 10, 20）

这些特征分别用于捕捉短期动量效应和波动性变化。

- 目标变量：**次日对数收益率 r_{t+1}
- 数据集划分：**按时间顺序将每只股票的数据划分为训练集（前 80%）与测试集（后 20%，即每只股票最后 50 天），保证模型在预测过程中不使用未来信息。

3. 模型方法

- Ridge 回归**

Ridge 回归是一种带 L2 正则项的线性回归模型，其目标函数为：

$$\min ||y - X\beta||^2 + \alpha ||\beta||^2$$

该模型可以缓解多重共线性问题，并防止在高噪声数据中出现过拟合，因此被广泛用于金融预测任务中的基线模型。

• Chronos 时间序列模型

Chronos 是一种基于 Transformer 架构的预训练时间序列模型，通过在大规模通用时间序列数据上训练来学习时间结构。在本作业中，对每只股票输入最近 30 天收益率作为上下文，预测下一日收益率，并对多次采样结果取均值作为最终预测。

• 通义千问 Qwen 模型


通过 DashScope API 调用通义千问 Qwen 模型，将历史收益率作为文本输入，请求模型给出预测值及解释。该模型不具备显式时间序列建模结构，仅作为启发式对比方法。

4.1 实验结果


模型	MAE：衡量预测误差的绝对平均值	RMSE：衡量预测误差的平方根平均值	测试样本数	测试股票数
Ridge	0.009996	0.015016	25,050	501
Chronos	0.101196	0.138047	1000	20
Qwen	无稳定改进			

Ridge 在误差指标上显著优于 Chronos，后者在该任务中表现较差。


4.2 可视化分析



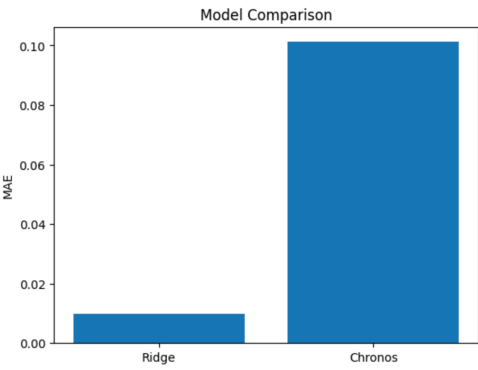
日收益率分布图，显示收益率高度集中于 0 附近，噪声较强。



Ridge 预测与真实值对比图，呈一定相关结构。



Chronos 预测与真实值对比图，相关性较弱。



模型 MAE 对比柱状图。

五、讨论与分析

从实验结果来看，Ridge 回归模型展现出了显著的优势。这主要得益于其背后系统的建模思路：精心设计的滞后与滚动统计特征，有效捕捉了金融时间序列的短期记忆与波动特性，为模型提供了高质量的输入信息；L2 正则化的引入则起到了防止过拟合的关键作用，提升了模型在未见数据上的泛化能力。此外，Ridge 回归采用的全局训练策略，即利用所有股票数据进行训练，使其能够学习到跨股票的共性市场模式，而极高的计算效率也使其非常适合处理大规模的金融数据。

反观 Chronos 模型在此次任务中表现不佳，其原因是多方面的。首先，模型本身的容量可能是一个限制，所使用的 t5-small 版本参数规模相对有限，可能难以充分捕捉金融序列中复杂的非线性模式和噪声结构。更深层的原因在于领域不匹配，预训练数据与金融收益率序列的分布存在显著差异，而本研究直接使用预训练模型，未针对金融数据进行任何微调或适应性训练，导致模型“水土不服”。在输入信息层面，模型仅依赖过去 30 天的单一收益率序列，未能引入任何其他维度的特征，信息量较为有限。同时，其预测基于随机采样并取均值，这种机制在原则上用于刻画预测不确定性，但在金融收益这种高度噪声、弱结构的任务中，反而可能引入额外随机扰动，并掩盖原本微弱的可预测信号。

当然，本研究也存在一些局限性。由于计算资源与时间限制，Chronos 模型仅在 20 只股票上进行了测试，这可能在一定程度上限制了结果的代表性，结论的普适性有待进一步验证。Ridge 回归的成功在很大程度上依赖于手工特征工程的质量，这既需要专业领域知识，也带来了主观性。此外，两种模型均未考虑市场所处的宏观状态（如牛市或熊市），而不同市场环境下序列的特征和可预测性可能存在系统性差异，忽略这一点可能影响了模型在极端市场条件下的稳健性。

六、结论与展望

本研究的主要结论是明确的：在本次针对 S&P 500 成分股次日对数收益率的预测任务中，结合了有效特征工程的 Ridge 回归模型显著优于未经调优的 Chronos 预训练模型。这一结果表明，在金融时间序列预测领域，传统统计模型与精心设计的特征工程相结合，仍然具有强大的竞争力与实用性。同时，它也揭示了一个关键问题：通用的预训练时间序列模型在直接应用于像金融这样具有高噪声和特殊规律性的领域时，往往需要进行针对性的领域适应和模型调优才能发挥其潜力。

基于以上发现，未来的研究工作可以从多个维度展开。在模型层面，可以尝试参数规模更大的 Chronos 模型变体（如 chronos-t5-large），并对模型在金融时间序列上进行系统的微调训练，以弥合领域差距；也可以探索集成学习框架，旨在融合传统模型的稳定性和深度学习模型捕捉复杂模式的能力。在信息输入层面，特征体系可以进一步扩展，例如引入经典技术指标（RSI、MACD 等）、整合基于新闻或社交媒体的市场情绪指标，甚至考虑宏观经济变量与特定事件的影响。在方法深化上，可以构建多模态的预测框架，并深入研究模型在不同市场波动环境下的稳健性表现，最终将预测信号应用于具体的投资策略并进行严格的回测验证，以评估其实际经济价值。

本作业的实践意义在于为金融时间序列预测的方法选择提供了一个实证参考。在计算资源有限、模型可解释性要求较高的应用场景中，以 Ridge 回归为代表的传统线性模型依然是可靠且高效的选择。而在数据充沛、能够接受一定“黑盒”特性、且具备足够模型调优能力的场景下，经过充分领域适配的深度学习模型则有望突破传统方法的瓶颈，展现出更大的预测潜力。两者的取舍与结合，应基于具体的业务需求、数据条件和资源约束来审慎决策。